Иван Турик

ML Engineer | Минск, Беларусь
github.com/ivanturik

vnturik@gmail.com
+375 44 567-84-00
t.me/b4h999

Технические навыки

Python, SQL, C++

pandas, NumPy, scikit-learn, imbalanced-learn, CatBoost, PyTorch, matplotlib

FastAPI, Streamlit, MLflow, Docker, Git, MCP, Hugging Face Transformers, A/B-тестирование

Проекты

- **Heart Disease Scoring — end-to-end ML-сервис**
  - Написал скрипт загрузки исходных данных **CDC NHANES** за **5 циклов** обследований; объединил разнородные XPT-таблицы, согласовал кодировки и сформировал датасет из **28 270 размеченных записей**.
  - Провёл **EDA** распределений и пропусков; подготовил признаки и пайплайн предобработки, разделил данные на train/validation/test с группировкой одинаковых профилей для снижения риска утечки.
  - Сравнил **8 моделей** и отслеживал эксперименты в **MLflow**; выбрал **CatBoost** по Average Precision на validation, подобрал порог по MCC с ограничением на Recall. На тесте: **Recall 0.752** при Precision 0.219.
  - Превратил модель в приложение: **FastAPI** с проверкой входных данных и обработкой пропусков, **Streamlit**-интерфейс с пояснениями к результату; настроил запуск через **Docker Compose**.
- **DocQA — поиск ответов на вопросы в тексте**
  - Дообучил **DistilBERT** на **SQuAD 1.1** для извлечения ответов из текста; реализовал обработку длинных контекстов методом скользящего окна и оптимизировал обучение с использованием mixed precision.
  - Достиг **Exact Match 76,93%** и **token-level F1 85,18%** на отложенной выборке; проанализировал ошибки определения границ ответа и зависимость качества от длины контекста.
  - Интегрировал дообученную модель в **Streamlit**-приложение для интерактивного тестирования и визуализации результатов.
- **Исследование методов обработки несбалансированных данных в задачах бинарной классификации**
  - Построил сравнительный бенчмарк **15 подходов** к дисбалансу классов (SMOTE, class weighting, ансамбли, подбор порога) на **4 реальных датасетах** и синтетических данных с соотношением классов **10:1–1000:1**.
  - Исследовал влияние шума, перекрытия классов и степени балансировки на качество и затраты обучения. В экспериментах SMOTE-модификации с Random Forest чаще давали лучший баланс precision и recall; на Fraud Detection достигнут **средний F1 = 0.866** за 3 разбиения.
  - Показал на Fraud Detection, что SMOTE + RF повышал **recall с 0.770 до 0.831** относительно Random Oversampling + RF при близком F1, но увеличивал число ложных тревог; при дисбалансе **1000:1** частичная балансировка оказалась эффективнее выравнивания 1:1.

Образование и достижения

Белорусский государственный университет, ФПМИ *2023–2027*

Прикладная математика

Курсы: Agents Week (ШАД); «Тренировки. ML-забег» (теория RL); курс машинного обучения Студенческого союза ФПМИ БГУ (1-й сезон).

Олимпиады и соревнования: заключительный этап Республиканской олимпиады по математике (2023); международный финал World Robot Olympiad (WRO), категория Open Elementary (2016, 2017).

Языки

Русский — родной • Английский — B2